

## Постановка задачи

В данном проекте будет рассматриваться следующая задача оптимизации:

$$\min_x f(x) := \mathbb{E}[F(x, \xi)]$$

при условии  $x \in X$ ,  $X$  – замкнутое выпуклое подмножество  $\mathbb{R}^n$ ,  $F(x, \xi) : X \rightarrow \mathbb{R}$  – функция из класса  $C^1(X)$ ,  $\xi$  – случайная величина.

## Метод SGD

Метод стохастического градиента получается из классического метода градиентного спуска заменой градиента  $\nabla f(x)$  на стохастический градиент  $G(x, \xi) = \partial_x F(x, \xi)$ . Если функция  $f$  является  $L$  – гладкой и  $\exists \sigma > 0 \mathbb{E}\|G(x, \xi) - \mathbb{E}[G(x, \xi)]\|_*^2 \leq \sigma^2$ , то оптимальная скорость сходимости принадлежит  $\mathcal{O}(\frac{L}{k^2} + \frac{\sigma}{\sqrt{k}})$ . Исследуемый в данном проекте алгоритм достигает указанной оптимальной скорости сходимости.

## Цель проекта

В данном проекте будет рассмотрен метод стохастического градиентного спуска A2Grad. А также будет достигнута оптимальная скорость сходимости  $\mathcal{O}(\frac{L}{k^2} + \frac{\sigma}{\sqrt{k}})$ , а также исследованы разные варианты размеров шагов.

## Стохастический градиентный спуск

Нашей целью будет найти новый градиентный метод, который за основу берёт продвинутый алгоритм Нестерова, использующий метод моментов и адаптивный алгоритм стохастического градиентного спуска.

Приведём алгоритм Adaptive SGD.

---

**Algorithm 1:** Adaptive algorithm

---

**Input:**  $x_0, v_0$

**for**  $k=0, 1, 2, \dots, K$  **do**

    Получаем  $\xi_k$  и вычисляем  $G_k \in \nabla F(x_k, \xi_k)$ ;  $v_k = \psi(G_0^2, G_1^2, G_2^2, \dots, G_k^2)$ ;

$G_k = \phi(G_0, G_1, G_2, \dots, G_k)$ ;

$x_{k+1} = x_k - \beta_k G_k / \sqrt{v_k}$ ;

**end**

---

# Adaptive ASGD

Определение:  $D_\phi(x, y) := \phi(x) - \phi(y) - \langle \nabla \phi(y), x - y \rangle$ , где  $\phi$  — выпуклая гладкая функция.

Для удобства положим  $D(x, y) = D_\psi(x, y)$ , где  $\psi(x) = \frac{1}{2}\|x\|^2$ .

Общий вид рассматриваемого в статье метода выглядит так:

---

## Algorithm 2: A2Grad algorithm

---

**Input:**  $x_0, \bar{x}_0, \gamma_k, \beta_k > 0$

**for**  $k=0, 1, 2, \dots, K$  **do**

$\underline{x}_k = (1 - \alpha_k)\bar{x}_k + \alpha_k x_k$ ;

    Получаем  $\xi_k$ , вычисляем  $\underline{G}_k \in \nabla F(\underline{x}_k, \xi_k)$  и  $\phi_k(\cdot)$ ;

$x_{k+1} = \arg \min \{ \langle \underline{G}_k, x \rangle + \gamma_k D(x_k, x) + \beta_k D_{\phi_k}(x_k, x) \}$ ;

$\bar{x}_{k+1} = (1 - \alpha_k)\bar{x}_k + \alpha_k x_{k+1}$ ;

**end**

**Output:**  $\bar{x}_{K+1}$

---

Осталось разобраться с выбором констант и функций.

В качестве  $\phi_k$  возьмём  $\frac{1}{2}\|x\|_{h_k}^2 = \frac{1}{2}\langle x^T, \text{diag}(h_k)x \rangle$ , где  $h_k \in \mathbb{R}^d$ ,  $h_{k,i} > 0$ . Тогда  $D_{\phi_k} = \frac{1}{2}\langle (x-y)^T, \text{diag}(h_k)(x-y) \rangle$ . То, что получилось, будем называть diagonal scaling. В такой версии алгоритма  $x_{k+1} = \text{proj} \left( x_k - \frac{1}{\gamma_k + \beta_k h_k} \underline{G}_k \right)$ .

Положим  $\alpha_k = \frac{2}{k+2}$ ,  $\gamma_k = \frac{2L}{k+1}$ ,  $\beta_k = \beta$ ,  $\beta$  — параметр алгоритма.

Для выбора  $h_k$  мы рассмотрим 3 способа:

- Uniform moving average

Положим  $v_{-1} = 0$ ,  $v_k = v_{k-1} + \delta_k^2$ ,  $h_k = \sqrt{v_k}$

- Incremental moving average

Положим  $v_{-1} = 0$ ,  $v_k = \frac{k^2}{(k+1)^2} v_{k-1} + \delta_k^2$ ,  $h_k = \sqrt{v_k}$

- Exponential moving average

$$\tilde{v}_k = \begin{cases} 0, & \text{если } k = -1 \\ \delta_k^2, & \text{если } k = 0 \\ \rho \tilde{v}_{k-1} + (1 - \rho) \delta_k^2, & \text{иначе} \end{cases}$$

$$v_k = \max(v_{k-1}, \tilde{v}_k)$$

$$h_k = \sqrt{(k+1)v_k}$$

Здесь  $\delta_k = \underline{G}_k - \frac{1}{k+1} \sum_{i=0}^k \underline{G}_i$ .

## Сходимость

**Теорема.** Если в алгоритме 2 функция  $f$  выпуклая и  $L$ -гладкая с константой  $L$ , и  $\{\alpha_k\}, \{\gamma_k\}$  удовлетворяют следующим условиям:

$$L\alpha_k \leq \gamma_k$$

$$\lambda_{k+1}\alpha_{k+1}\gamma_{k+1} \leq \lambda_k\alpha_k\gamma_k$$

где последовательность  $\{\lambda_k\}$  - это:

$$\lambda_0 = 1$$

$$\lambda_k = \frac{1}{\prod_{i=1}^k (1 - \alpha_i)}$$

Тогда верно следующее неравенство:

$$\lambda_K [f(\bar{x}_{K+1}) - f(x)] \leq (1 - \alpha_0) [f(\bar{x}_0) - f(x)] + \alpha_0 \gamma_0 D(x_0, x) +$$

$$+ \sum_{k=0}^K K \lambda_k \left[ \lambda_k \frac{\alpha_k \|\delta_k\|_{\phi_{k^*}}^2}{2\beta_k} + \alpha_k \langle \delta_k, x - x_k \rangle + \alpha_k R_k \right]$$

, где  $\delta_k = \underline{G}_k - \nabla f(x_k)$  и  $R_k = \beta_k D_{\phi_k}(x_k, x) - \beta_k D_{\phi_k}(x_{k+1}, x)$

**Теорема.** Пусть  $x^*$  — глобальный минимум, причем  $\exists B > 0 \ \|x_k - x^*\|_\infty^2 < B$ . Пусть в схеме exponential moving average  $\rho \in (0, 1)$ , и распределение ошибки  $\delta_k$  таково, что  $\exists \sigma \geq 0 \ \forall t > 0 \ \mathbb{E} e^{t\delta_k} \leq e^{t^2 \sigma^2 / 2}$ . Тогда

$$\mathbb{E}[f(\bar{x}_{K+1}) - f(x^*)] \leq \frac{2L\|x^* - x_0\|^2}{(K+1)(K+2)} + 2\beta B \frac{\sqrt{2 \log(2(K+1))}\sigma}{\sqrt{K+2}} + \frac{\sqrt{2\pi}d\sigma}{2\beta(1-\rho)\sqrt{K+2}}$$

.

## Анализ литературы

В ходе анализа литературы было получено, что описанный в статье метод является state-of-the-art среди стохастических градиентных методов.

## Эмпирические результаты

Описанные в статье три версии A2Grad (uniform, incremental, exponential moving average) были протестированы на линейной регрессии и логистической регрессии против Adam, SGD и LBFGS (квазиньютоновский метод). Итак, на логистической регрессии описанные в статье методы показали лучший результат. На линейной регрессии incremental moving average сходится медленно, что согласуется с результатами в статье.

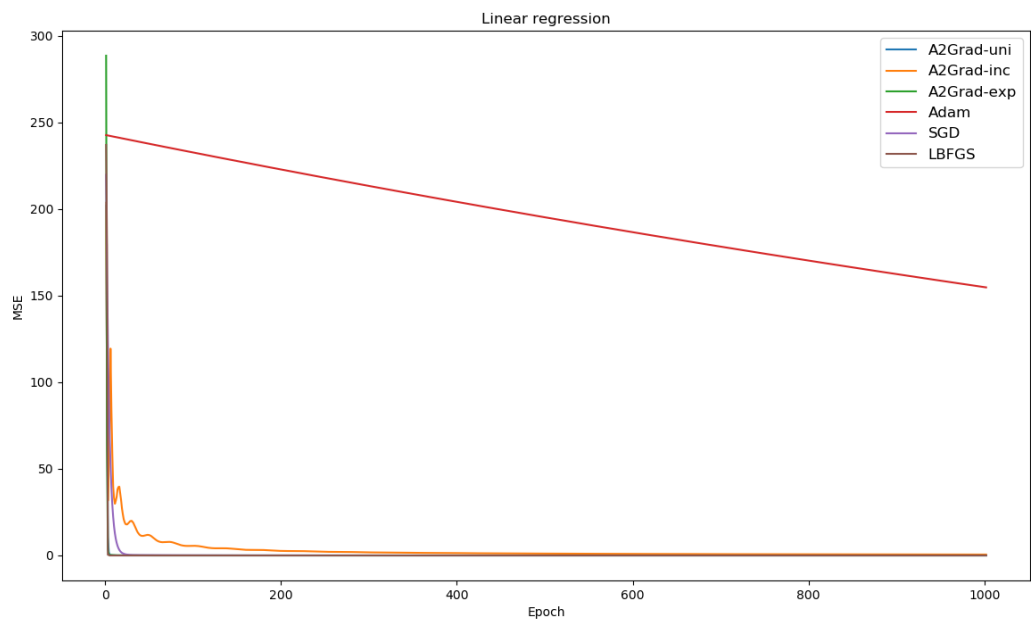


Рис. 1: Linear regression

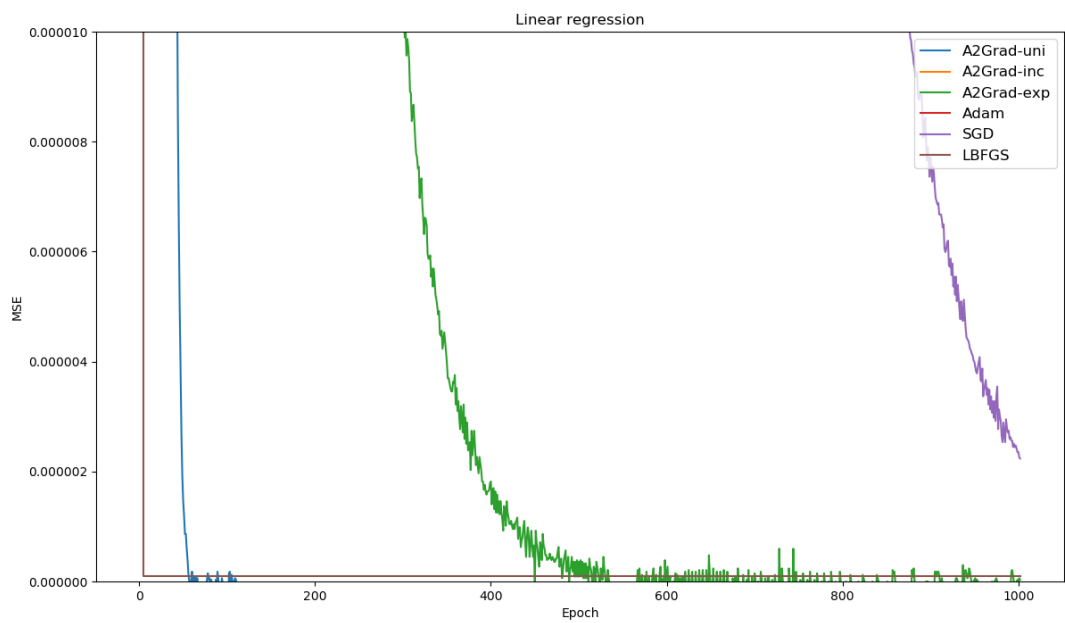


Рис. 2: Linear regression

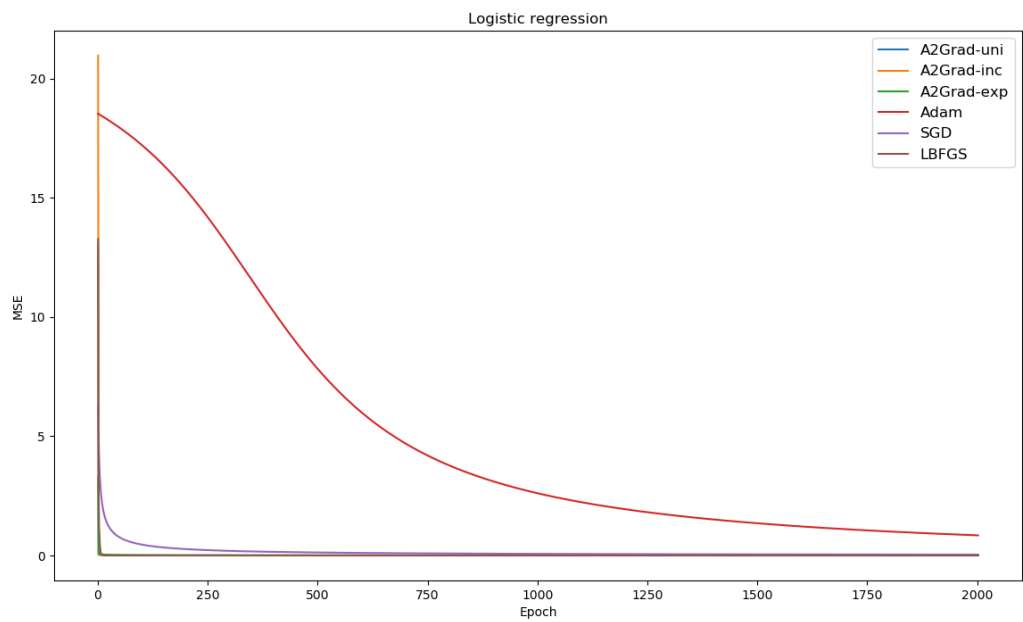


Рис. 3: Logistic regression

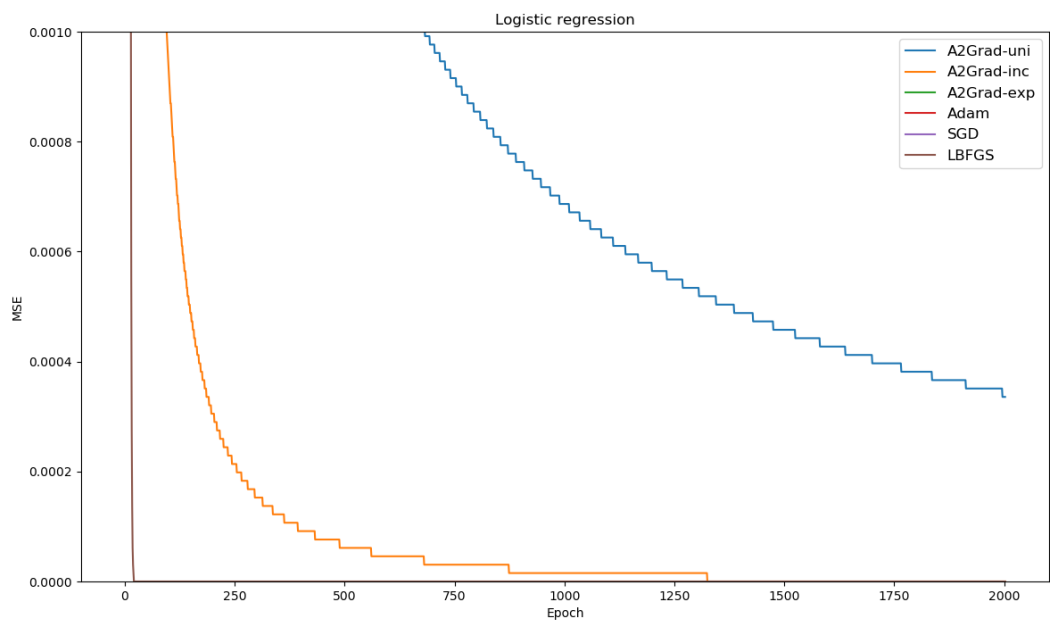


Рис. 4: Logistic regression